Retrouver le nom du patient

Une heuristique à base de règles : où elle échoue, et comment la mise en page la corrige

Alexandre Rogojan

Lifen · stage Machine Learning Engineer · partie 1

1 La tâche : un JSON en entrée, un nom en sortie

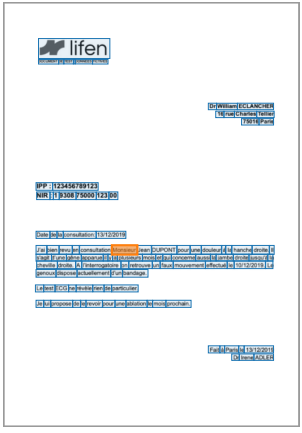
Entrée	Sortie	Contrainte
Chaque mot de la page avec sa boîte : x et y vont de 0 à 1 depuis le coin en haut à gauche. Les mots arrivent dans un ordre quelconque.	Le prénom et le nom du patient, ou `None` quand le document ne donne aucun indice clair.	L'heuristique la plus simple : pas d'apprentissage automatique, un code court que tout le monde peut lire.

Notation. Une page est un ensemble de mots $D = \{(t_i, b_i)\}_{i=1}^{n}$, où t_i est le texte du mot et $b_i = (x_i^{\min}, x_i^{\max}, y_i^{\min}, y_i^{\max}) \in [0,1]^4$ sa boîte. On veut :

$$f(D) = (\text{prénom}, \text{nom})$$

```
find_patient(document) ⟶ ('Jean', 'DUPONT')
```

1.1 Ce que contient le JSON



Document 3 : une boîte par mot, « Monsieur » en orange.

Chaque mot est un objet JSON :

```
{"text": "Monsieur",
 "bbox": {"x_min": 0.37, "x_max": 0.45,
          "y_min": 0.57, "y_max": 0.59}}
```

Un extrait de la page, dans un ordre quelconque :

text	x_min	x_max	y_min	y_max
jusqu'à	0.83	0.89	0.59	0.61
douleur	0.67	0.74	0.57	0.59
Monsieur	0.37	0.45	0.57	0.59
123	0.31	0.35	0.45	0.46
s'agit	0.11	0.16	0.59	0.61

- 110 mots lus par OCR. x : 0 au bord gauche, 1 au bord droit ; y : 0 en haut, 1 en bas.
- Seules les boîtes disent où est un mot : l'heuristique ne lit jamais l'image.

2 L'heuristique minimale : deux règles, dans l'ordre

Algorithme 1 : heuristique minimale (`find_patient`)

Entrée : un document : des pages, chacune avec ses mots et leurs boîtes
Sortie : (prénom, nom) du patient, ou `None`

pour chaque page du document **faire**
  $m_1, \ldots, m_k \leftarrow$ les mots de la page dans l'ordre de lecture ▷ étape 1
  si un mot m_i vaut `Nom:` **alors** ▷ règle 1
    retourner (mot après `Prénom:`, mot après `Nom:`)
  pour chaque civilité m_i (Monsieur, Madame, Mme…) **faire** ▷ règle 2
    si m_{i-1} n'est pas un titre de médecin (Dr, Docteur, Pr…) **alors**
      $N \leftarrow$ au plus deux mots après m_i, arrêt au premier mot en minuscule
      si $N = (n)$, **retourner** (`None`, n) ; **si** $N = (p, n)$, **retourner** (p, n)
retourner `None`

La première règle qui trouve un nom répond : aucun score, aucune comparaison.

2.1 Étape 1 : remettre les mots dans l'ordre de lecture

1. Trier les mots par $(y^{\min}, x^{\min})$.
2. Nouvelle ligne quand $y^{\min}$ saute de plus de $\delta = 0{,}005$.
3. Trier chaque ligne par $x^{\min}$.

Pourquoi des lignes ? Sur le document 1, « Juliette » est 0,0003 plus bas que ses voisins :



(y, x) seul : `Madame MARTIN Juliette` ×
lignes, puis x : `Madame Juliette MARTIN` ✓

```python
def read_words(page):
    words = []
    for word in page["words"]:
        y = word["bbox"]["y_min"]
        x = word["bbox"]["x_min"]
        words.append((y, x, word["text"]))
    words.sort()
    lines = []
    previous_y = 0
    for y, x, text in words:
        if len(lines) == 0 or y - previous_y > LINE_GAP:
            lines.append([])
        lines[-1].append((x, text))
        previous_y = y
    result = []
    for line in lines:
        line.sort()
        for x, text in line:
            result.append(text)
    return result
```

2.2 Règle 1 : un formulaire, `Nom:` et `Prénom:`



Document 2 : les étiquettes en violet, les mots qui les suivent en vert.

Dans l'ordre de lecture : … `BRÊS Patient: Elle est Chirurgienne` **`Nom: Hugo Prénom: Victor`** …

- On garde le mot qui suit `Nom:` et celui qui suit `Prénom:`, ce qui donne `('Victor', 'Hugo')`.
- La ligne mélange les deux colonnes (« Elle est Chirurgienne » vient de la colonne de gauche), mais le mot juste après `Nom:` reste « Hugo ».
- La comparaison est exacte : `Nom :` (avec une espace) ou `Nom de naissance :` ne déclenchent pas la règle. Pas de `Nom:` sur la page : la règle 2 prend le relais.

2.3 Règle 2 : la première civilité qui ne suit pas un titre de médecin

Puis lire au plus deux mots après elle, tant qu'ils commencent par une majuscule.

Document	Mots, dans l'ordre de lecture	Résultat
Document 3	consultation **Monsieur Jean DUPONT** pour	`('Jean', 'DUPONT')`
Document 1	Timone **Madame Juliette MARTIN**	`('Juliette', 'MARTIN')`
Document 1, plus bas	le **docteur Monsieur** Nicolas JACQUES	ignoré : le mot d'avant est un titre de médecin
Document 2	revoir **Mme HUGO** *un* jour	`(None, 'HUGO')` : « un » est en minuscule

Orange : la civilité ; **vert** : le nom lu ; **rouge** : un titre de médecin juste avant. Sur le document 1, « Madame » répond avant que « docteur Monsieur » soit atteint ; sur le document 2, la règle 1 a déjà répondu.

2.4 Le code : des boucles et des `if`, rien de plus

Règle 1

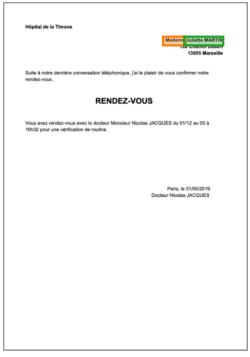
```
def find_patient(document):
    for page in document["pages"]:
        words = read_words(page)
        first_name = None
        last_name = None
        for i in range(len(words) - 1):
            word = words[i].lower()
            if word == "nom:":
                last_name = words[i + 1]
            if word == "prénom:":
                first_name = words[i + 1]
        if last_name is not None:
            return first_name, last_name
```

Règle 2

```
        for i in range(len(words)):
            word = words[i].lower()
            if word not in CIVILITIES:
                continue
            if i > 0 and words[i - 1].lower() in DOCTOR_TITLES:
                continue
            name = []
            for j in range(i + 1, i + 3):
                if j >= len(words):
                    break
                if words[j].lower() in DOCTOR_TITLES:
                    break
                if not words[j][0].isupper():
                    break
                name.append(words[j].strip("."))
            if len(name) == 1:
                return None, name[0]
            if len(name) == 2:
                return name[0], name[1]
    return None
```

62 lignes de code en tout, sans les commentaires : trois constantes, `read_words` et `find_patient`.

2.5 Résultats sur les trois documents du challenge



(a) Règle 2, « Madame » `('Juliette', 'MARTIN')`



(b) Règle 1, `Nom:` et `Prénom:` `('Victor', 'Hugo')`



(c) Règle 2, « Monsieur » `('Jean', 'DUPONT')`

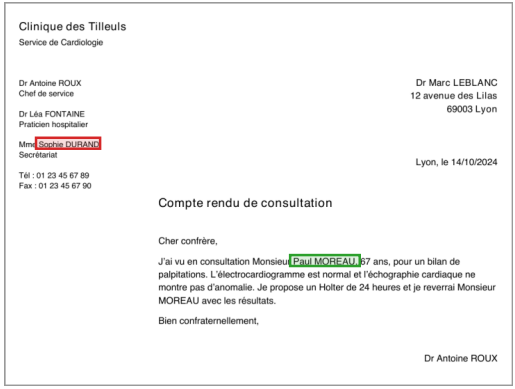
En orange ou violet, l'indice ; en vert, le nom renvoyé. Aussi vérifié : 18 tests unitaires, les vraies boîtes OCR des trois pages, des mots mélangés et des lignes légèrement irrégulières.

3 Où elle échoue : quatre documents ordinaires

Cas	Patient	Version minimale	Type d'erreur
Bandeau du personnel	Paul MOREAU	Sophie DURAND	mauvaise personne
Étiquette d'hôpital	Jean DUPONT	`None`	aucune réponse
Bloc d'identité	Camille LEROY	`None`	aucune réponse
Proche cité en premier	Pierre DURAND	Claire PETIT	mauvaise personne

- **Mauvaise personne** : un faux positif, et le vrai patient est manqué. C'est l'erreur la plus grave : le document irait dans le dossier d'un autre patient.
- **Aucune réponse** : un faux négatif. Le document part en vérification humaine : coûteux, mais sans danger.

3.1 Elle renvoie la mauvaise personne



Clinique des Tilleuls
Service de Cardiologie

Dr Antoine ROUX
Chef de service

Dr Léa FONTAINE
Praticien hospitalier

Mme Sophie DURAND
Secrétariat

Tél : 01 23 45 67 89
Fax : 01 23 45 67 90

Dr Marc LEBLANC
12 avenue des Lilas
69003 Lyon

Lyon, le 14/10/2024

Compte rendu de consultation

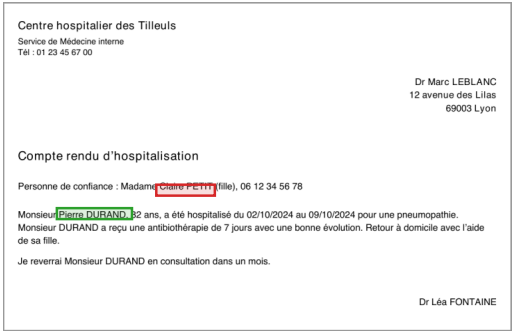
Cher confrère,

J'ai vu en consultation Monsieur Paul MOREAU, 67 ans, pour un bilan de palpitations. L'électrocardiogramme est normal et l'échographie cardiaque ne montre pas d'anomalie. Je propose un Holter de 24 heures et je reverrai Monsieur MOREAU avec les résultats.

Bien confraternellement,

Dr Antoine ROUX

(a) **Bandeau du personnel.** « Mme Sophie DURAND », la secrétaire, vient en premier dans l'ordre de lecture.



Centre hospitalier des Tilleuls
Service de Médecine interne
Tél : 01 23 45 67 00

Dr Marc LEBLANC
12 avenue des Lilas
69003 Lyon

Compte rendu d'hospitalisation

Personne de confiance : Madame Claire PETIT (fille), 06 12 34 56 78

Monsieur Pierre DURAND, 82 ans, a été hospitalisé du 02/10/2024 au 09/10/2024 pour une pneumopathie. Monsieur DURAND a reçu une antibiothérapie de 7 jours avec une bonne évolution. Retour à domicile avec l'aide de sa fille.

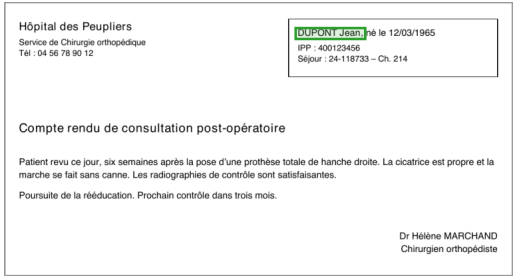
Je reverrai Monsieur DURAND en consultation dans un mois.

Dr Léa FONTAINE

(b) **Proche cité en premier.** « Personne de confiance : Madame Claire PETIT » précède le patient.

Rouge : la réponse de la version minimale ; vert : le patient.

3.2 Elle ne trouve rien



Hôpital des Peupliers
Service de Chirurgie orthopédique
Tél : 04 56 78 90 12

DUPONT Jean, né le 12/03/1965
IPP : 400123456
Séjour : 24-118733 – Ch. 214

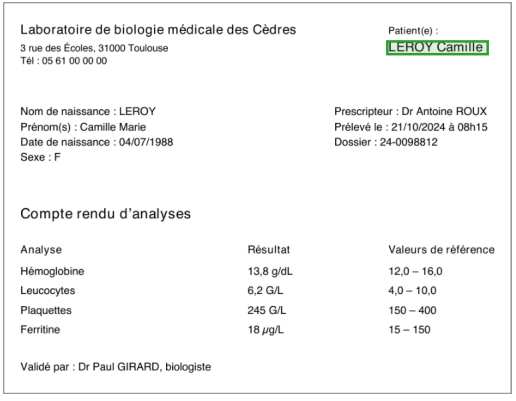
Compte rendu de consultation post-opératoire

Patient revu ce jour, six semaines après la pose d'une prothèse totale de hanche droite. La cicatrice est propre et la marche se fait sans canne. Les radiographies de contrôle sont satisfaisantes.

Poursuite de la rééducation. Prochain contrôle dans trois mois.

Dr Hélène MARCHAND
Chirurgien orthopédiste

(a) **Étiquette d'hôpital.** Le nom n'apparaît que dans « DUPONT Jean, né le 12/03/1965 » : ni civilité, ni `Nom:`.



Laboratoire de biologie médicale des Cèdres
3 rue des Écoles, 31000 Toulouse
Tél : 05 61 00 00 00

Patient(e) :
LEROY Camille

Nom de naissance : LEROY
Prénom(s) : Camille Marie
Date de naissance : 04/07/1988
Sexe : F

Prescripteur : Dr Antoine ROUX
Prélevé le : 21/10/2024 à 08h15
Dossier : 24-0098812

Compte rendu d'analyses

Analyse	Résultat	Valeurs de référence
Hémoglobine	13,8 g/dL	12,0 – 16,0
Leucocytes	6,2 G/L	4,0 – 10,0
Plaquettes	245 G/L	150 – 400
Ferritine	18 µg/L	15 – 150

Validé par : Dr Paul GIRARD, biologiste

(b) **Bloc d'identité.** `Nom de naissance :` et `Prénom(s) :` ne sont pas exactement `Nom:` et `Prénom:`.

Vert : le patient, que la version minimale ne trouve pas (elle renvoie `None`).

3.3 Pourquoi elle échoue : trois causes

1. Une seule liste à plat

Bandeaux, adresses et signatures sont lus exactement comme la lettre elle-même.

2. La première trouvée gagne

La première civilité répond, même quand elle désigne une secrétaire ou un proche.

3. Deux sortes d'indices

Rien pour « né le », pour `Nom de naissance :`, ni pour une étiquette placée au-dessus du nom.

La correction suit ces trois causes : lire la page **par blocs**, garder **tous les indices** au lieu du premier, et en reconnaître **plus de sortes**.

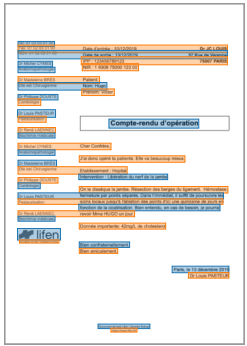
4 La correction : lire la page par blocs, puis voter

Algorithme 2 : version « mise en page »

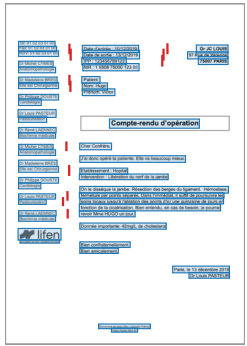
Entrée : un document : des pages, chacune avec ses mots et leurs boîtes
Sortie : (prénom, nom) du patient, ou `None`

$s(n) \leftarrow 0$ pour tout nom de famille n
pour chaque page du document **faire**
    lignes $\leftarrow$ mots triés par (y, x) ; nouvelle ligne si l'écart en y dépasse 0,005
    morceaux $\leftarrow$ lignes coupées où deux mots sont à plus de 0,05 en x
    blocs $\leftarrow$ chaque morceau sous le bloc juste au-dessus (même colonne, écart $< 0{,}012$)
    pour chaque bloc dont aucune ligne ne commence par Dr, Pr, Tél ou Fax **faire**
        pour chaque indice : étiquette (3 points), civilité (2), « né le » (2) **faire**
            $(p, n) \leftarrow$ au plus deux mots à majuscule après l'indice ▷ capitales : nom
            $s(n) \leftarrow s(n) +$ points de l'indice
$\hat{n} \leftarrow \arg\max_n s(n)$
si $s(\hat{n}) \geq 2$, **retourner** $(\hat{p}, \hat{n})$; **sinon**, **retourner** `None`

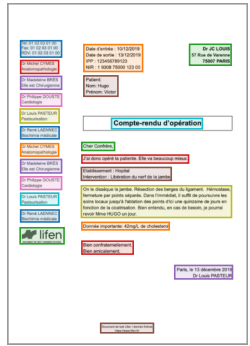
4.1 Reconstruire la page : lignes, morceaux, blocs



(a) **40 lignes.** Une nouvelle ligne quand l'écart en y dépasse 0,005.



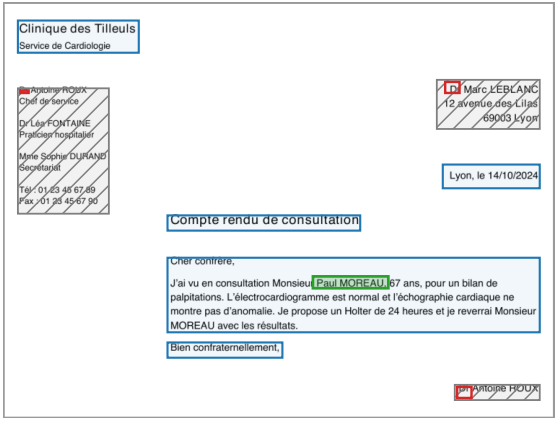
(b) **52 morceaux.** Une ligne est coupée (trait rouge) quand deux mots sont à plus de 0,05 en x.



(c) **24 blocs.** Un morceau rejoint le bloc juste au-dessus, dans la même colonne, si l'écart est $< 0{,}012$.

Document 2, vraies boîtes OCR. Les deux colonnes, mélangées dans les lignes (a), sont séparées dans les blocs (c).

4.2 Ignorer les blocs de contact



- Un bloc dont une ligne commence par un titre de médecin, « Tél » ou « Fax » est ignoré : en-tête, bandeau du personnel, adresse du destinataire, signature.
- Ici, « Mme Sophie DURAND » est dans le bandeau : elle est ignorée. La seule civilité qui reste est « Monsieur Paul MOREAU ».

Gris hachuré : bloc ignoré, à cause du mot encadré en rouge ; bleu : bloc lu ; vert : le patient trouvé.

4.3 Trois sortes d'indices, chacune avec des points

Indice	Exemple	Points
Étiquette en début de ligne : `Nom`, `Prénom(s)`, `Patient`, jusqu'aux deux-points	`Nom de naissance :` **LEROY**, `Prénom(s) :` **Camille** Marie	3
Civilité, sauf juste après un titre de médecin	**Monsieur Pierre DURAND**, 82 ans	2
Naissance : les deux mots avant « né le »	**DUPONT Jean**, **né le** 12/03/1965	2

Lire le nom. Au plus deux mots qui commencent par une majuscule, arrêt sur une virgule. Un mot tout en capitales est le nom de famille, même s'il vient en premier : « DUPONT Jean » donne `('Jean', 'DUPONT')`.

4.4 Voter : additionner les points par nom de famille

Soit $\mathcal{C}(n)$ l'ensemble des indices qui donnent le nom de famille n (sans tenir compte de la casse). Alors

$$s(n) = \sum_{c \in \mathcal{C}(n)} \text{points}(c), \qquad \hat{n} = \arg\max_{n} s(n), \qquad \text{réponse} = \begin{cases} (\hat{p}, \hat{n}) & \text{si } s(\hat{n}) \geq 2, \\ \texttt{None} & \text{sinon.} \end{cases}$$

Nom de famille	**Indices trouvés, cas du proche cité en premier**	**Score**
DURAND	« Monsieur Pierre DURAND », puis « Monsieur DURAND » deux fois	$2 + 2 + 2 = \mathbf{6}$
PETIT	« Madame Claire PETIT »	2

Réponse : `('Pierre', 'DURAND')`. Le seuil 2 règle le compromis : plus haut, le système répond moins souvent mais plus sûrement (moins de faux positifs, plus de faux négatifs).

4.5 Résultats : les quatre cas sont corrigés

Document	Version minimale	Mise en page	Ce qui corrige
Bandeau du personnel	Sophie DURAND	Paul MOREAU	le bandeau est ignoré : ses lignes commencent par « Dr » et « Tél »
Étiquette d'hôpital	`None`	Jean DUPONT	l'indice « né le », puis les capitales : DUPONT est le nom
Bloc d'identité	`None`	Camille LEROY	les étiquettes `Nom de naissance :` et `Prénom(s) :`
Proche cité en premier	Claire PETIT	Pierre DURAND	le vote : DURAND 6 points, PETIT 2

Les trois documents du challenge donnent toujours les mêmes réponses.

4.6 Mesurer : précision, rappel et F1

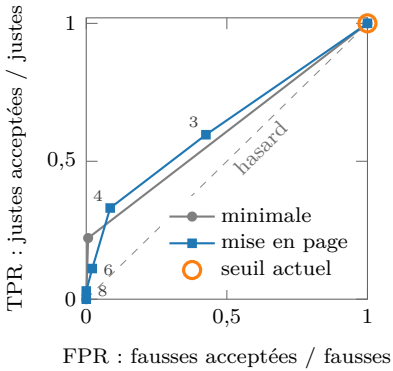
Pour chaque document : une **bonne réponse** est un vrai positif (VP) ; un **mauvais nom** est un faux positif (FP) et manque le patient (FN) ; **aucune réponse** est un faux négatif (FN).

$$\text{précision} = \frac{\text{VP}}{\text{VP} + \text{FP}}, \qquad \text{rappel} = \frac{\text{VP}}{\text{VP} + \text{FN}}, \qquad F_1 = \frac{2 \cdot \text{précision} \cdot \text{rappel}}{\text{précision} + \text{rappel}}$$

	Issue des 7 documents					
Version	bonne	mauvais nom	aucune	**Précision**	**Rappel**	**F_1**
Minimale	3	2	2	$3/5 = 60\,\%$	$3/7 \approx 43\,\%$	0,50
Mise en page	7	0	0	$7/7 = 100\,\%$	$7/7 = 100\,\%$	1,00

Sur les 7 documents de cette présentation (les 3 du challenge et les 4 cas). Ils ont été choisis pour montrer les échecs : ce n'est pas une évaluation. Il faut un jeu de test annoté plus grand, et faire varier le seuil du vote : c'est la suite.

4.7 Faire varier le seuil : la courbe ROC

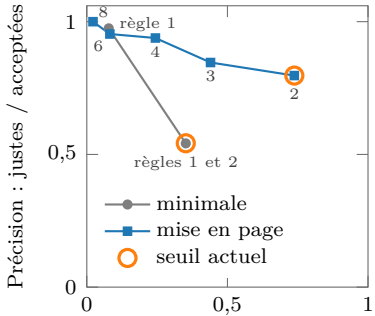


Nombres : seuils τ (mise en page).

Jeu de test : 500 documents synthétiques, 6 sortes (lettres, étiquettes, biologie…), noms tirés au hasard. Le mélange est notre choix : les chiffres en dépendent.

- **Score c.** Mise en page : $c = s(\hat{n})$, le total des votes. Minimale : $c = 2$ si la règle 1 répond, 1 pour la règle 2.
- **Seuil τ.** Si $c \geq \tau$, la réponse est acceptée ; sinon, vérification humaine. Un seuil donne un point.
- **Positif** : réponse juste, prénom et nom exacts. Les documents sans réponse ne sont pas sur la courbe.
- **AUC** $= \Pr(c_{\text{juste}} > c_{\text{fausse}})$, égalité : $\frac{1}{2}$. Ici 0,61 et 0,63 ; hasard : 0,5 ; parfait : 1.
- **Seuil actuel** (orange) : `MIN_SCORE = 2` accepte tout, car chaque indice vaut au moins 2 points.

4.8 Précision et rappel selon le seuil



Un point par seuil τ ; orange : seuil actuel.

Mêmes 500 documents. IC à 95 % de l'AUC (bootstrap) : [0,58 ; 0,64] pour la minimale, [0,58 ; 0,68] pour la mise en page.

Seuil actuel	Minimale	Mise en page
bonne réponse	176	369
mauvais nom	149	94
aucune réponse	175	37
Précision	54 %	80 %
Rappel	35 %	74 %
F_1	0,43	0,77
AUC	0,61	0,63

- AUC proches, mais deux fois plus de bons noms : la ROC ignore les documents sans réponse.
- Seuil 4 : précision 94 %, rappel 24 %. À 3 points, 27 mauvais noms sur 32 sont des fiches à deux colonnes, où `Nom :` lit « Date ».

5 À retenir : les règles marchent, jusqu'à la prochaine mise en page

Version minimale

62 lignes

Deux règles. Juste sur les trois documents du challenge, fausse ou vide sur les quatre cas ordinaires.

Version mise en page

112 lignes

Blocs, indices et votes. Corrige les quatre cas, mais un formulaire dont les valeurs sont loin de leurs étiquettes la met encore en échec.

Ensuite : apprendre

Partie 2

Les règles couvrent les cas un par un, et leur score sépare mal le juste du faux (AUC 0,63). Un modèle apprend ces régularités à partir de documents annotés.

Lignes de code sans commentaires ni lignes vides.