Challenge Data Lifen

Heuristique

Alexandre Rogojan

Lifen · stage Machine Learning Engineer · partie 1

1 Extraire le nom du patient :

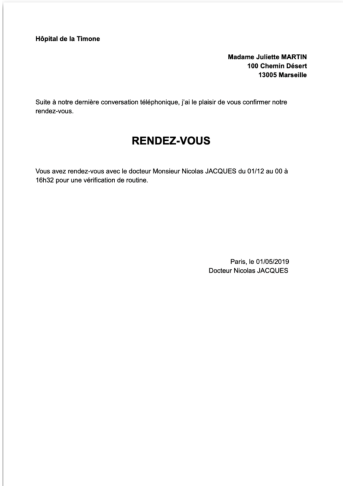
Entrée	**Sortie**
Mots de la page avec positions : x et y vont de 0 à 1 depuis le coin en haut à gauche. Les mots arrivent dans un ordre quelconque.	Le prénom et le nom du patient, ou `None`.

Notation. Une page est un ensemble de mots $D = \{(t_i, b_i)\}_{i=1}^{n}$, où t_i est le texte du mot et $b_i = (x_i^{\min}, x_i^{\max}, y_i^{\min}, y_i^{\max}) \in [0,1]^4$ sa boîte. On veut :

$$f(D) = (\text{prénom}, \text{nom})$$

`find_patient(document)` $\longrightarrow$ `('Jean', 'DUPONT')`

Exemples de documents médicaux :



Hôpital de la Timone

Madame Juliette MARTIN
100 Chemin Désert
13005 Marseille

Suite à notre dernière conversation téléphonique, j'ai le plaisir de vous confirmer notre rendez-vous.

RENDEZ-VOUS

Vous avez rendez-vous avec le docteur Monsieur Nicolas JACQUES du 01/12 au 00 à 16h32 pour une vérification de routine.

Paris, le 01/05/2019
Docteur Nicolas JACQUES



Tel: 01 02 03 01 00
Fax: 01 02 03 01 00
RDV: 01 02 03 01 00

Dr Michel CYMES
Anatomopathologie

Dr Madeleine BRÈS
Elle est Chirurgienne

Dr Philippe DOUSTE
Cardiologie

Dr Louis PASTEUR
Pasteurisation

Dr René LAENNEC
Biochimie médicale

Dr Michel CYMES
Anatomopathologie

Dr Madeleine BRÈS
Elle est Chirurgienne

Dr Philippe DOUSTE
Cardiologie

Dr Louis PASTEUR
Pasteurisation

Dr René LAENNEC
Biochimie médicale

lifen
DOCUMENT DE TEST / DONNÉES FICTIVES

Date d'entrée : 10/12/2019
Date de sortie : 13/12/2019
IPP : 123456789123
NIR : 1 9308 75000 123 00

Dr JC LOUIS
57 Rue de Varenne
75007 PARIS

Patient:
Nom: Hugo
Prénom: Victor

Compte-rendu d'opération

Cher Confrère,

J'ai donc opéré ta patiente. Elle va beaucoup mieux.

Etablissement : Hopital
Intervention : Libération du nerf de la jambe

On le disséque la jambe. Résection des berges du ligament. Hémostase, fermeture par points séparés. Dans l'immédiat, il suffit de poursuivre les soins locaux jusqu'à l'ablation des points d'ici une quinzaine de jours en fonction de la cicatrisation. Bien entendu, en cas de besoin, je pourrai revoir Mme HUGO un jour.

Donnée importante: 42mg/L de cholesterol

Bien confraternellement.
Bien amicalement.

Paris, le 13 décembre 2019
Dr Louis PASTEUR

Document de test Lifen / données fictives
https://www.lifen.fr/



lifen
DOCUMENT DE TEST / DONNÉES FICTIVES

Dr William ECLANCHER
16 rue Charles Tellier
75016 Paris

IPP : 123456789123
NIR : 1 9308 75000 123 00

Date de la consultation: 13/12/2019

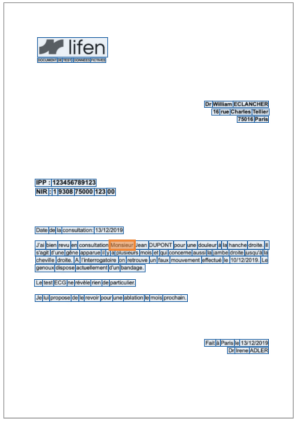
J'ai bien revu en consultation Monsieur Jean DUPONT pour une douleur à la hanche droite. Il s'agit d'une gêne apparue il y a plusieurs mois et qui concerne aussi la jambe droite jusqu'à la cheville droite. A l'interrogatoire on retrouve un faux mouvement effectué le 10/12/2019. Le genoux dispose actuellement d'un bandage.

Le test ECG ne révèle rien de particulier.

Je lui propose de le revoir pour une ablation le mois prochain.

Fait à Paris le 13/12/2019
Dr Irene ADLER

1.1 JSON en entrée


lifen
Dr William ECLANCHER
10 rue Charles Tellier
75019 Paris
IPP : 12345678123
NIR : 1 91 08 75 009 123 00
Date de la consultation : 13/12/2019
J'ai bien revu en consultation Monsieur Jean DUPONT pour une douleur à la hanche droite. Il n'a pas d'antécédent particulier à signaler. Il me raconte aujourd'hui qu'il a ressenti une douleur brutale lors d'un mouvement de la jambe droite il y a deux jours. Il a interrompu son activité sportive depuis. Il a consulté son médecin traitant qui lui a prescrit du repos et des anti-inflammatoires. Il a ressenti une amélioration partielle de la douleur mais il a toujours mal lorsqu'il marche. Il a donc décidé de consulter un spécialiste. Il ne présente pas de fièvre, pas de frissons, pas de troubles urinaires. Il ne présente pas de douleur lombaire irradiant dans la jambe. A l'interrogatoire on retrouve un faux mouvement d'effectué le 10/12/2019. Il a également consulté aux urgences où il a bénéficié d'une radiographie qui n'a pas montré de fracture. Il a été mis au repos et on lui a prescrit un traitement antalgique. Il a également bénéficié d'une infiltration de corticoïdes qui a permis de diminuer la douleur. Il a également bénéficié d'une prise en charge en kinésithérapie. Il a également bénéficié d'une prise en charge en ostéopathie. Il a également bénéficié d'une prise en charge en acupuncture. Il a également bénéficié d'une prise en charge en homéopathie. Il a également bénéficié d'une prise en charge en phytothérapie. Il a également bénéficié d'une prise en charge en aromathérapie. Il a également bénéficié d'une prise en charge en naturopathie. Il a également bénéficié d'une prise en charge en chiroprax

2 Étape 1 : reconstruction du texte.

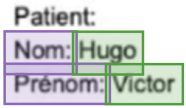
1. Tuples $(y^{\min}, x^{\min}, texte)$.
2. Tri lexicographique sur les tuples : trie d'abord par y puis par x sur les tuples.
3. Nouvelle ligne quand $y^{\min}$ saute de plus de $\delta = 0{,}005$.

Doc1 : « Juliette » 0,0003 que les autres mots sur sa ligne.




```
def read_words(page):
    words = []
    for word in page["words"]:
        y = word["bbox"]["y_min"]
        x = word["bbox"]["x_min"]
        words.append((y, x, word["text"]))
    words.sort()
    lines = []
    previous_y = 0
    for y, x, text in words:
        if len(lines) == 0 or y - previous_y > LINE_GAP:
            lines.append([])
        lines[-1].append((x, text))
        previous_y = y
    result = []
    for line in lines:
        line.sort()
        for x, text in line:
            result.append(text)
    return result
```

2.1 Règle n.1 : `Nom:` et `Prénom:`



Document 2 : labels et noms

- On garde le mot qui suit `Nom:` et celui qui suit `Prénom:`, ce qui donne `('Victor', 'Hugo')`.
- La comparaison est exacte : `Nom :` (avec une espace) ou `Nom de naissance :` ne déclenchent pas la règle. Pas de `Nom:` sur la page : la règle 2 prend le relais.

2.2 Règle n.2 : civilité

Document	Mots, dans l'ordre de lecture	Résultat
Document 3	consultation **Monsieur Jean DUPONT** pour	`('Jean', 'DUPONT')`
Document 1	Timone **Madame Juliette MARTIN**	`('Juliette', 'MARTIN')`
Document 1, plus bas	le **docteur Monsieur** Nicolas JACQUES	ignoré : le mot avant la civilité est un titre de médecin
Document 2	revoir **Mme HUGO** *un* jour	`(None, 'HUGO')` : « un » est en minuscule
Autre cas pris en charge	**Monsieur** le **docteur** Nicolas JACQUES	ignoré : le mot après la civilité est un titre de médecin.

2.3 Code :

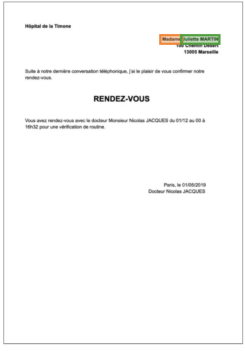
Règle 1

```
def find_patient(document):
    for page in document["pages"]:
        words = read_words(page)
        first_name = None
        last_name = None
        for i in range(len(words) - 1):
            word = words[i].lower()
            if word == "nom:":
                last_name = words[i + 1]
            if word == "prénom:":
                first_name = words[i + 1]
        if last_name is not None:
            return first_name, last_name
```

Règle 2

```
        for i in range(len(words)):
            word = words[i].lower()
            if word not in CIVILITIES:
                continue
            if i > 0 and words[i - 1].lower() in DOCTOR_TITLES:
                continue
            name = []
            for j in range(i + 1, i + 3):
                if j >= len(words):
                    break
                if words[j].lower() in DOCTOR_TITLES:
                    break
                if not words[j][0].isupper():
                    break
                name.append(words[j].strip("."))
            if len(name) == 1:
                return None, name[0]
            if len(name) == 2:
                return name[0], name[1]
    return None
```

2.4 Résultats sur les trois exemples du challenge



(a) Règle 2, « Madame » `('Juliette', 'MARTIN')`



(b) Règle 1, `Nom:` et `Prénom:` `('Victor', 'Hugo')`



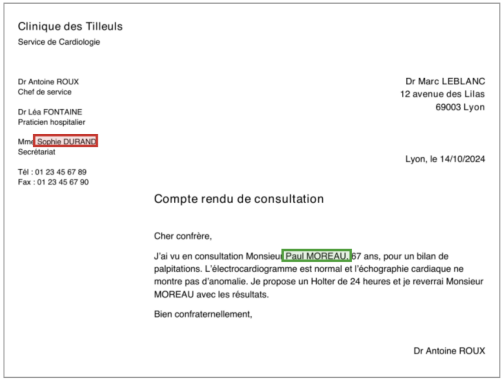
(c) Règle 2, « Monsieur » `('Jean', 'DUPONT')`

3 Cas où les règles échouent :

Cas	Patient	Version minimale	Type d'erreur
Bandeau du personnel	Paul MOREAU	Sophie DURAND	mauvaise personne
Étiquette d'hôpital	Jean DUPONT	`None`	aucune réponse
Bloc d'identité	Camille LEROY	`None`	aucune réponse
Proche cité en premier	Pierre DURAND	Claire PETIT	mauvaise personne

- **Mauvaise personne** : faux positif, le vrai patient est manqué. Erreur : le document irait dans le dossier d'un autre patient.
- **Aucune réponse** : faux négatif.

3.1 Faux positifs :



Clinique des Tilleuls
Service de Cardiologie

Dr Antoine ROUX
Chef de service

Dr Léa FONTAINE
Praticien hospitalier

Mme Sophie DURAND
Secrétariat

Tél : 01 23 45 67 89
Fax : 01 23 45 67 90

Dr Marc LEBLANC
12 avenue des Lilas
69003 Lyon

Lyon, le 14/10/2024

Compte rendu de consultation

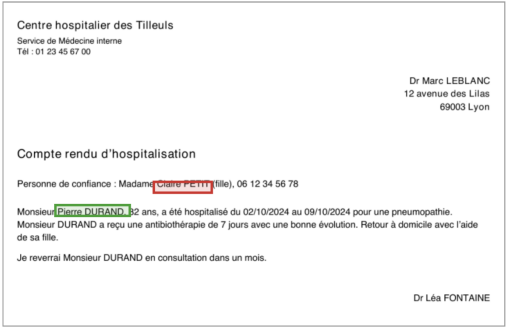
Cher confrère,

J'ai vu en consultation Monsieur Paul MOREAU, 57 ans, pour un bilan de palpitations. L'électrocardiogramme est normal et l'échographie cardiaque ne montre pas d'anomalie. Je propose un Holter de 24 heures et je reverrai Monsieur MOREAU avec les résultats.

Bien confraternellement,

Dr Antoine ROUX

(a) **Bandeau du personnel.** « Mme Sophie DURAND », la secrétaire, vient en premier dans l'ordre de lecture.



Centre hospitalier des Tilleuls
Service de Médecine interne
Tél : 01 23 45 67 00

Dr Marc LEBLANC
12 avenue des Lilas
69003 Lyon

Compte rendu d'hospitalisation

Personne de confiance : Madame Claire PETIT (fille), 06 12 34 56 78

Monsieur Pierre DURAND, 82 ans, a été hospitalisé du 02/10/2024 au 09/10/2024 pour une pneumopathie. Monsieur DURAND a reçu une antibiothérapie de 7 jours avec une bonne évolution. Retour à domicile avec l'aide de sa fille.

Je reverrai Monsieur DURAND en consultation dans un mois.

Dr Léa FONTAINE

(b) **Proche cité en premier.** « Personne de confiance : Madame Claire PETIT ».

Rouge : la réponse de la version minimale ; vert : le patient.

3.2 Faux négatifs :



Hôpital des Peupliers
Service de Chirurgie orthopédique
Tél : 04 56 78 90 12

DUPONT Jean, né le 12/03/1965
IPP : 400123456
Séjour : 24-118733 – Ch. 214

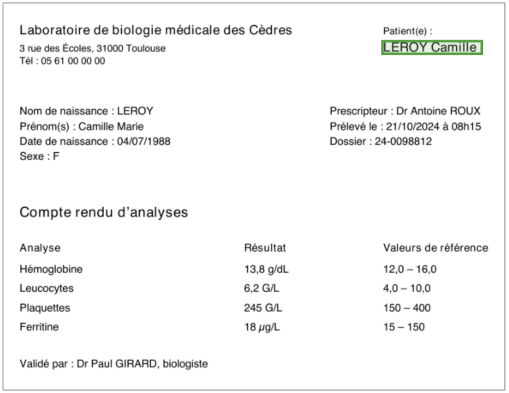
Compte rendu de consultation post-opératoire

Patient revu ce jour, six semaines après la pose d'une prothèse totale de hanche droite. La cicatrice est propre et la marche se fait sans canne. Les radiographies de contrôle sont satisfaisantes.

Poursuite de la rééducation. Prochain contrôle dans trois mois.

Dr Hélène MARCHAND
Chirurgien orthopédiste

(a) **Étiquette d'hôpital.** Pas de civilité, pas de "Nom:", "Prénom:". L'heuristique renvoie $(None, None)$.



Laboratoire de biologie médicale des Cèdres
3 rue des Écoles, 31000 Toulouse
Tél : 05 61 00 00 00

Patient(e) :
LEROY Camille

Nom de naissance : LEROY
Prénom(s) : Camille Marie
Date de naissance : 04/07/1988
Sexe : F

Prescripteur : Dr Antoine ROUX
Prélevé le : 21/10/2024 à 08h15
Dossier : 24-0098812

Compte rendu d'analyses

Analyse	Résultat	Valeurs de référence
Hémoglobine	13,8 g/dL	12,0 – 16,0
Leucocytes	6,2 G/L	4,0 – 10,0
Plaquettes	245 G/L	150 – 400
Ferritine	18 µg/L	15 – 150

Validé par : Dr Paul GIRARD, biologiste

(b) **Bloc d'identité.**
`"Nom de naissance :"` $\neq$ `"Nom:"`
L'heuristique renvoie $(None, None)$.

3.3 Causes des faux positifs et faux négatifs

1. Une seule liste à plat

Bandeaux, adresses et signatures sont lus exactement comme la lettre elle-même. L'heuristique n'exploite pas l'information "spatiale" encodée dans les bbox.

2. Deux règles uniquement, pas de contexte

Rien pour « né le », pour `Nom de naissance :`, ni pour une étiquette placée au-dessus du nom.

4 Idées pour améliorer l'heuristique :

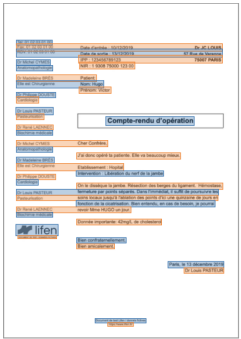
1. Exploiter l'agencement spatial des mots (offert dans le fichier JSON)

L'idée est de reconstruire des "blocs" qu'un humain identifie visuellement lors de la lecture d'un texte. Puis de filtrer sur chaque bloc.

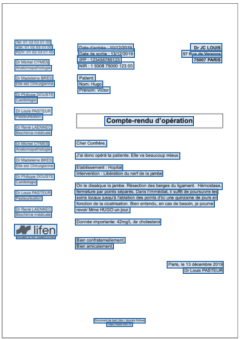
2. Une meilleure heuristique : un score par bloc

Si le bloc contient un titre de médecin "Dr.", "Docteur",... alors on l'ignore. Si le bloc contient "né le", "né(e) le", "Nom:", ou une civilité alors on attribue un score plus ou moins élevé à la chaîne de caractères en majuscules dans ce bloc (on exploite le fait que le NOM DE FAMILLE soit écrit en majuscules).

4.1 Exploiter l'agencement de la page : découper la page par blocs



(a) **Lignes.** Une nouvelle ligne quand l'écart en y dépasse 0,005.

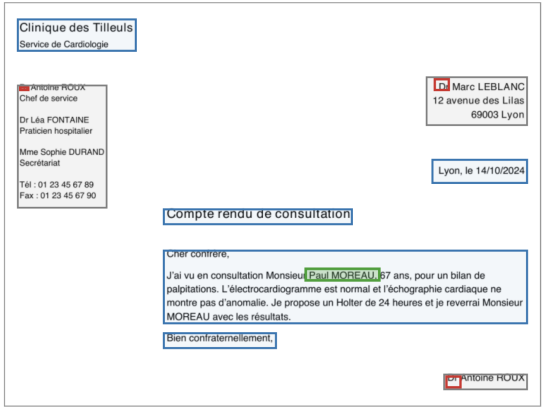


(b) Découpage horizontal des lignes. Une ligne est coupée quand deux mots sont à plus de 0,05 d'écart sur l'axe x.



(c) **Blocs.** Un morceau rejoint le bloc juste au-dessus, dans la même colonne, si l'écart vertical est $< 0{,}012$.

4.2 Ignorer les blocs de contact et les titres :



- Un bloc contenant : un titre de médecin, « Tél » ou « Fax » est ignoré.
- Ici, « Mme Sophie DURAND » est dans le bandeau : elle est ignorée. La seule civilité restante est celle juste devant « Paul MOREAU ».

4.3 Trois attributions de score :

Indice	Exemple	Points
Étiquette en début de ligne : `Nom`, `Prénom(s)`, `Patient`, jusqu'aux deux-points	`Nom de naissance :` **LEROY**, `Prénom(s) :` **Camille** Marie	3
Civilité, sauf juste après un titre de médecin	**Monsieur Pierre DURAND**, 82 ans	2
Naissance : les deux mots avant « né le »	**DUPONT Jean**, **né le** 12/03/1965	2

On récupère ici le nom de famille (en majuscules).

4.4 Vote : additionner les points par nom de famille

Soit $\mathcal{C}(n)$ l'ensemble des indices qui donnent le nom de famille n (sans tenir compte de la casse). Alors

$$score(n) = \sum_{c \in \mathcal{C}(n)} \text{points}(c), \qquad \hat{n} = \arg\max_{n} score(n), \qquad \text{réponse} = \begin{cases} (\widehat{prenom}, \widehat{nom}) & \text{si } \geq 2, \\ \texttt{None} & \text{sinon.} \end{cases}$$

Nom de famille	**Indices trouvés, cas du proche cité en premier**	**Score**
DURAND	« Monsieur Pierre DURAND », bloc4 « Monsieur DURAND » bloc11&14	$2 + 2 + 2 = \mathbf{6}$
PETIT	« Madame Claire PETIT »	2

Réponse : `('Pierre', 'DURAND')`.

4.5 Précision, rappel et F1 de l'heuristique

Pour chaque document : une **bonne réponse** est un vrai positif (VP) ; un **mauvais nom** est un faux positif (FP), **aucune réponse** est un faux négatif (FN).

$$\text{précision} = \frac{\text{VP}}{\text{VP} + \text{FP}}, \qquad \text{rappel} = \frac{\text{VP}}{\text{VP} + \text{FN}}, \qquad F_1 = \frac{2 \cdot \text{précision} \cdot \text{rappel}}{\text{précision} + \text{rappel}}$$

	Issue des 7 documents					
Version	bonne	mauvais nom	aucune	**Précision**	**Rappel**	**F_1**
Heuristique du repo	3	2	2	$3/5 = 60\,\%$	$3/7 \approx 43\,\%$	0,50
Découpage par blocs	7	0	0	$7/7 = 100\,\%$	$7/7 = 100\,\%$	1,00